

Detecção de Placas Veiculares com MobileNetV1 e Detector por Grade Embarcado em ESP32-S3

Carlos Vinícius dos Santos Mesquita
Victor Guedes Alves Teixeira

Alisson Jaime Sales Barros
Kaique Ferreira Braga Silva

TI0147 – Fundamentos de Processamento Digital de Imagens

Professor: Paulo Cesar Cortez

30 de junho de 2026

Resumo

Este trabalho apresenta um sistema completo de detecção de placas veiculares baseado na arquitetura **MobileNetV1** com uma cabeça de *detector por grade* (saída espacial $7 \times 7 \times 5$), treinado em TensorFlow/Keras e embarcado em uma placa **ESP32-S3** com câmera OV5640. O modelo foi quantizado em INT8 e convertido para TensorFlow Lite, viabilizando a inferência diretamente no microcontrolador. Avaliamos o sistema em três modalidades (imagem, vídeo e captura em tempo real com a ESP32-CAM), comparamos o desempenho entre PC e dispositivo embarcado, e aplicamos pós-processamento com filtragem por confiança e segmentação dos caracteres. Os resultados, obtidos sobre **5 execuções**, mostram IoU médio de $0,731 \pm 0,005$ no conjunto combinado e *recall* de 0,922, com a quantização INT8 preservando a qualidade (IoU praticamente idêntico ao modelo Keras). A inferência custa $\sim 4\text{--}7$ ms no PC contra ~ 117 s na ESP32-S3, evidenciando o gargalo do hardware embarcado. O acréscimo de imagens negativas reduziu os falsos positivos a zero no limiar 0,95.

1 Introdução

A detecção de objetos é uma tarefa central da Visão Computacional, consistindo em localizar objetos de interesse por meio de *bounding boxes*. Sua execução em sistemas embarcados, contudo, é desafiadora: dispositivos como a ESP32 possuem forte restrição de memória e processamento. Arquiteturas da família MobileNet, baseadas em convoluções separáveis em profundidade (*depthwise separable convolutions*), foram projetadas para esse cenário, reduzindo parâmetros e custo computacional.

Este trabalho desenvolve, treina e embarca um detector de placas veiculares usando MobileNetV1 com uma cabeça de detecção por grade, e o avalia nas três modalidades exigidas (imagem, vídeo e tempo real). Além do embarcamento na ESP32-S3, o mesmo modelo é executado em PC para comparação de desempenho, e o sistema é complementado por pós-processamento (filtragem por confiança e segmentação dos caracteres da placa).

Tabela 1: Divisão da base utilizada (uma classe: `plate`).

Conjunto	Treino	Validação
Base 1 (professor)	350	60
Base 2 (Brazil Plates)	200	12
Mix ponderado	972	72
Negativas (sem placa)	12	4

2 Base de Dados

Foram utilizadas duas bases de detecção de objetos de classe única (`plate`), com anotações no formato YOLO (centro, largura e altura normalizados): **Base 1**, fornecida pelo professor, e **Base 2**, a base pública *Brazil Plates Detector* (Roboflow, licença CC BY 4.0), escolhida pela aderência ao problema. As bases foram combinadas com ponderação da Base 2 para reforçar exemplos difíceis. A Tabela 1 resume a divisão efetivamente utilizada. Adicionalmente, incorporamos **16 imagens negativas** (cenas sem placa) para reduzir falsos positivos.

3 Arquitetura e Detector por Grade

A arquitetura é a **MobileNetV1** com fator de largura (*width multiplier*) $\alpha = 0,5$ e entrada $224 \times 224 \times 3$. Sobre o *backbone* pré-treinado adicionamos uma **cabeça de detecção por grade** que produz uma saída espacial $7 \times 7 \times 5$: a imagem é dividida em uma grade 7×7 e cada célula prevê uma confiança de objetos (*objectness*) e os quatro parâmetros da caixa (c_x, c_y, w, h) . A detecção final corresponde à célula de **maior confiança**, e a caixa global é reconstruída por $c_x = (\text{col} + c_x^{\text{local}})/7$ e $c_y = (\text{lin} + c_y^{\text{local}})/7$. Essa formulação resolveu o problema de localização da região correta da placa observado em abordagens de regressão direta de uma única caixa. A escolha do MobileNetV1 $\alpha = 0,5$ equilibra precisão e tamanho, essencial para o embarcamento.

4 Metodologia

4.1 Pré-processamento

As imagens são redimensionadas para 224×224 e normalizadas para o intervalo $[-1, 1]$ por $x_{norm} = x/127,5 - 1$. Avaliamos dois modos de cor: **RGB** e **gray3** (escala de cinza replicada em três canais), este último por vezes mais robusto a variações de cor. Durante o treino aplicamos *Data Augmentation*: espelhamento horizontal, variações de brilho/contraste, ruído e desfoque.

4.2 Treinamento

O treino emprega o otimizador Adam em duas fases (*transfer learning* seguido de *fine-tuning* da cabeça): 12 e 50 épocas, *batch* 8, com `ReduceLROnPlateau` e `EarlyStopping`, e função de perda combinando confiança (objectness) e regressão da caixa. Cada configuração foi executada **5 vezes**, reportando-se média e desvio padrão (Seção 5). O ambiente de treino foi o Google Colab (TensorFlow 2.20.0, Python 3.12, GPU [especificar modelo da GPU do Colab]).

4.3 Pós-processamento

Aplicamos **filtragem por confiança**: a detecção só é considerada válida quando a confiança ultrapassa o limiar 0,95 e se mantém por **2 frames consecutivos**, reduzindo disparos espúrios. Em seguida, realizamos a **segmentação dos caracteres** da placa (obrigatória) por técnicas clássicas de OpenCV: recorte da ROI, equalização local (CLAHE), realce por *BlackHat*, limiarização de Otsu/adaptativa e filtragem de componentes conectados (Figura 2).

4.4 Conversão e Quantização para a ESP32

O modelo Keras foi convertido para TensorFlow Lite em três variantes (Float32, *dynamic* e INT8). A quantização **INT8 pós-treinamento** foi escolhida para o embarcamento. O arquivo `.tflite` (2,35 MB) foi convertido em um `array C++ (xxd -i)`, gerando um cabeçalho de **2.468.584 bytes**. No firmware (Arduino/ESP-IDF, biblioteca `TensorFlowLite_ESP32`), o *tensor arena* ($\sim 3,4$ MB) é alocado na PSRAM e uma tabela de partições personalizada de 5 MB acomoda o aplicativo (3,74 MB de *flash*). A placa é uma **ESP32-S3** (16 MB *flash*, 8 MB PSRAM OPI, CPU a 240 MHz) com câmera **OV5640**.

4.5 Condições Experimentais

O **treinamento e a avaliação das métricas** foram realizados no Google Colab (TensorFlow 2.20.0,

Tabela 2: Métricas em 5 execuções (média $\pm$ desvio).

Métrica	Base 1	Base 2	Mix
IoU médio	$0,768 \pm 0,002$	$0,543 \pm 0,030$	$0,731 \pm 0,005$
Recall (IoU $\geq 0,5$)	$0,973 \pm 0,013$	$0,667 \pm 0,075$	$0,922 \pm 0,014$
F1@0,5	0,983	0,750	0,944

Score balanceado: $0,655 \pm 0,015$.

Tabela 3: Tempo de inferência, tamanho e IoU (conjunto Mix).

Plataforma / modelo	Tempo	Tamanho	IoU
Keras (PC, float)	$\sim 96,9$ ms	—	0,736
TFLite Float32 (PC)	$\sim 6,5$ ms	8,75 MB	0,736
TFLite INT8 (PC, LiteRT)	$\sim 4-7$ ms	2,35 MB	0,732
TFLite INT8 (ESP32-S3)	~ 117 s	2,35 MB	—

Python 3.12, GPU NVIDIA do Google Colab). Os **testes em PC** (execução LiteRT/TFLite) usaram um notebook com CPU Intel Core i7-14700HX, 16 GB de RAM, Windows 11 (64 bits), Python 3.14. O **dispositivo embarcado** é uma ESP32-S3 (16 MB *flash*, 8 MB PSRAM OPI, CPU a 240 MHz) com câmera OV5640, usando a biblioteca `TensorFlowLite_ESP32` (Arduino-ESP32 3.3.8 / ESP-IDF 5.5).

5 Resultados

5.1 Desempenho de detecção (5 execuções)

A Tabela 2 apresenta as métricas médias e desvios das 5 execuções. O modelo atinge *recall* elevado na Base 1 e no conjunto combinado; o desempenho menor na Base 2 reflete sua maior dificuldade e menor tamanho.

5.2 Comparação PC vs. ESP32 e validação da quantização

A Tabela 3 compara plataformas. A quantização INT8 **preservou a qualidade** (IoU praticamente idêntico ao Keras), reduzindo o modelo de 8,75 MB (Float32) para 2,35 MB. No PC a inferência custa poucos milissegundos; na ESP32-S3, ~ 117 s por *frame* — cerca de $1,7 \times 10^4$ vezes mais lenta. O gargalo decorre dos *kernels* de referência da biblioteca TFLite Micro e do acesso à PSRAM, não do modelo em si.

5.3 Efeito das imagens negativas

A Tabela 4 mostra os falsos positivos sobre imagens sem placa em função do limiar. No limiar adotado (0,95) não há falsos positivos, e os exemplos positivos não foram degradados (confiança média $\sim 0,99$). Medições na própria ESP32-S3 confirmaram o ganho: cenas sem placa caíram

Tabela 4: Falsos positivos em imagens sem placa por limiar.

Limiar	0,50	0,90	0,95	0,98
Falsos positivos	4/4	1/4	0/4	0/4



Figura 1: Detecção em imagem: entrada, caixa prevista (confiança $\approx 1,0$) e mapa de confiança da grade 7×7 .

de $\sim 0,62$ (modelo antigo) para $0,42$ – $0,58$, enquanto uma placa real bem enquadrada atinge $0,98$ – $0,99$.

5.4 Avaliação nas três modalidades

Imagem. A Figura 1 mostra a detecção em uma imagem: a caixa é posicionada corretamente sobre a placa e o mapa de confiança da grade destaca a célula correta.

Vídeo. O modelo foi executado quadro a quadro sobre uma sequência de vídeo (Figura 3), atingindo confiança de até $0,996$ no melhor *frame*, com taxa de processamento de centenas de FPS no PC. **Tempo real.** A captura ao vivo com a OV5640 acoplada à ESP32-S3 produziu detecção embarcada com confiança $0,97$, disparando o envio automático da imagem anotada (Telegram). A Figura 4 ilustra a correta *rejeição* de um quadro sem placa nítida (confiança abaixo de $0,95$).

6 Discussão

A quantização INT8 mostrou-se vantajosa: reduziu o modelo em $\sim 73\%$ sem perda mensurável de IoU, viabilizando o embarcamento. A principal limitação é o **tempo de inferência na ESP32-S3** (~ 117 s/*frame*), atribuível aos *kernels* de referência da TFLite Micro e à latência da PSRAM — e não ao tamanho do modelo, já que o mesmo arquivo roda em milissegundos no PC. As imagens negativas eliminaram os falsos positivos no limiar de operação. A qualidade da câmera OV5640 e o desfoque por movimento afetam a confiança, mitigados por bom enquadramento e pela exigência de detecção estável por múltiplos *frames*.

7 Conclusão e Trabalhos Futuros

Desenvolvemos um detector de placas com MobileNetV1 e cabeça por grade, embarcado e funcional na ESP32-S3,



Figura 2: Pós-processamento: ROI da placa, máscara de segmentação e caracteres segmentados (OpenCV).

avaliado nas três modalidades e comparado ao PC. A solução é viável e precisa, com a quantização preservando a qualidade. Como trabalhos futuros: (i) acelerar a inferência embarcada com *kernels* otimizados (ESP-NN) ou entrada menor (96×96); (ii) alternativamente, transmitir a captura da ESP32-CAM para inferência em servidor (*frontend* fluido); (iii) ampliar a base de negativas com fotos capturadas pela própria ESP-CAM; e (iv) reconhecimento óptico (OCR) dos caracteres já segmentados.

Referências

- [1] HOWARD, A. G. et al. *MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications*. arXiv:1704.04861, 2017.
- [2] ABADI, M. et al. *TensorFlow: Large-Scale Machine Learning on Heterogeneous Systems*. 2015. <https://www.tensorflow.org>.
- [3] *TensorFlow Lite / LiteRT Guide*. <https://www.tensorflow.org/lite>.
- [4] Roboflow. *Brazil Plates Detector Dataset*. <https://universe.roboflow.com/testes-bbb7m/brazil-plates-detector-zn2t0>.
- [5] CHOLLET, F. et al. *Keras*. <https://keras.io>.
- [6] Espressif. *ESP-IDF / ESP32-S3 Technical Reference*. <https://docs.espressif.com>.



Figura 3: Detecção em vídeo (melhor *frame*, confiança 0,996).



Figura 4: Rejeição correta: quadro sem placa nítida, confiança abaixo do limiar.